

Estimação de Probabilidade de Agravamento em Pacientes com Dengue utilizando Redes Neurais Artificiais (MLP)

Erick Thadeu Sales Praxedes

Bacharelado Interdisciplinar em Tecnologia da Informação

Departamento de Engenharias e Tecnologia (DETEC)

Universidade Federal Rural do Semi-Árido (UFERSA)

Pau dos Ferros, Brasil

erik.praxedes@alunos.ufersa.edu.br

Matrícula: 2023011180

Resumo—A dengue figura como um dos maiores desafios de saúde pública no mundo tropical. Em 2024, o Brasil registrou a pior epidemia de sua história, contabilizando mais de 6,4 milhões de casos e ultrapassando as fatalidades da pandemia de COVID-19 naquele ano. Visando mitigar o colapso do sistema de triagem clínica, este trabalho propõe o desenvolvimento de uma Rede Neural do tipo Perceptron de Múltiplas Camadas (MLP) para prever o risco de agravamento dos pacientes com base estritamente em exames e sintomas. Devido à extrema poluição estrutural nos dados abertos do Governo Federal de 2024 e 2025, utilizou-se um dataset validado da região de Bangladesh. O modelo atingiu resultados expressivos, especialmente uma Revocação (Recall) de 88,29% e F1-Score de 83,40%, garantindo a segurança diagnóstica graças à implementação de pesos de penalização de classe. O trabalho discute ainda as métricas alcançadas e as limitações estruturais intrínsecas a modelos unicamente clínicos, que ignoram variáveis fundamentais como a pobreza local e a deficiência infraestrutural de saúde.

Index Terms—Inteligência Artificial, Dengue, MLP, Sistemas Inteligentes, PyTorch.

I. INTRODUÇÃO

No Brasil, as arboviroses representam uma carga inestimável ao sistema de saúde. O ano de 2024 ficou marcado nos registros epidemiológicos como o cenário da maior e mais letal epidemia de dengue já vista no país. Conforme dados veiculados pela Secretaria de Vigilância em Saúde e Ambiente (SVSA) do Ministério da Saúde e por órgãos de imprensa, os casos prováveis ultrapassaram a marca de 6,4 milhões [1]. Ainda mais alarmante foi a taxa de letalidade: a dengue superou os óbitos causados pela COVID-19 em 2024, atingindo aproximadamente 6.000 mortes confirmadas em território nacional. Mesmo no início de 2025, os números mantêm-se como uma emergência sanitária [1].

Diante do volume massivo de pacientes adentrando as Unidades de Pronto Atendimento (UPAs), o tempo de triagem médica é um fator definitivo entre a vida e a morte. O agravamento clínico, que frequentemente culmina no quadro de Dengue Grave (historicamente chamada de febre hemorrágica da dengue), precisa ser detectado o mais cedo possível para a administração oportuna de hidratação intravenosa maciça.

O objetivo inicial desta pesquisa seria o treinamento de algoritmos de Inteligência Artificial sobre a base oficial do Governo Federal (DataSUS/SINAN) referente à transição 2024/2025 [3]. Contudo, ao realizar a exploração inicial, observou-se que a base do governo encontrava-se drasticamente poluída: havia uma enorme despadronização nas notificações, ausência quase integral de campos laboratoriais fundamentais (como contagem de plaquetas) e ruído excessivo nas colunas de evolução dos pacientes. Tais fatores impossibilitaram as tratativas matemáticas e a filtragem estrita exigidas por algoritmos de aprendizado de máquina.

Como alternativa rigorosa, este estudo adotou o *Dengue Dataset of Bangladesh* [2], um repositório clinicamente validado que detalha marcadores sorológicos (NS1, IgG, IgM) e sintomas determinantes (mialgia, exantema, dor retro-orbital, plaquetas). Sobre estes dados, foi implementado um *Multilayer Perceptron* (MLP) utilizando o *framework* PyTorch, desenhado não apenas para classificar, mas para punir agressivamente Falsos Negativos, garantindo segurança na triagem.

O presente artigo detalha a modelagem desta rede, as transformações realizadas na engenharia de características (*Feature Engineering*), analisa de forma crítica as métricas aferidas apontando para a escassez de parâmetros comparativos específicos, e expõe as limitações sociais enfrentadas por sistemas inteligentes aplicados à saúde em países em desenvolvimento.

II. FUNDAMENTAÇÃO TEÓRICA

A. Perceptron de Múltiplas Camadas (MLP)

O MLP é uma rede neural feedforward caracterizada por apresentar pelo menos três camadas de nós: uma camada de entrada, camadas ocultas e uma camada de saída. Cada nó (exceto os da entrada) é um neurônio que utiliza uma função de ativação não linear. A propagação da informação x ao longo de uma camada l pode ser descrita matricialmente pela Equação (1):

$$h^{(l)} = \sigma(W^{(l)} \cdot h^{(l-1)} + b^{(l)}) \quad (1)$$

Onde W representa a matriz de pesos sinápticos, b é o vetor de vies (*bias*) e σ é a função de ativação (neste modelo, adotou-se predominantemente a *Rectified Linear Unit* - ReLU). O treinamento é feito mediante o algoritmo de Retropropagação (*Backpropagation*), que calcula os gradientes do erro em relação aos pesos para que o otimizador os atualize iterativamente.

B. Trabalhos Relacionados e Originalidade

Durante a revisão da literatura para a construção deste artigo, realizou-se uma busca ativa por trabalhos acadêmicos que utilizassem especificamente o *Dengue Dataset of Bangladesh* [2] aplicando Redes Neurais Artificiais para prever o risco de agravamento a partir das dores articulares limitantes e perfis laboratoriais.

Foi constatado que não há, até o momento da escrita, trabalhos consolidados e disponíveis nas principais bases de dados científicas que utilizem esse exato recorte de dados geográficos e temporais sob a mesma métrica metodológica desenvolvida neste estudo. Essa ausência de literatura correlata direta impossibilita a comparação um-para-um de métricas. Consequentemente, isso eleva o caráter de originalidade desta pesquisa, estabelecendo o modelo arquitetural, a engenharia de *features* aplicada, e os resultados obtidos (Acurácia, *Precision*, *Recall* e *F1-Score*) como um *baseline* inicial (ponto de partida) empírico para futuros trabalhos focados nesta exata base de dados de Bangladesh.

III. METODOLOGIA E IMPLEMENTAÇÃO

A. A Base de Dados e Extração do Alvo (Target)

A base adotada (*Dengue Dataset of Bangladesh*) original consiste em 1.000 instâncias compostas por atributos demográficos, laboratoriais e clínicos.

A primeira fase da metodologia foi o isolamento geográfico e socioeconômico. Variáveis como gênero, área, tipo de área, tipo de moradia e distrito foram descartadas da matriz preditiva. A exclusão é justificada cientificamente pelo objetivo do modelo: analisar a capacidade de uma IA de aprender **fisiologicamente** as assinaturas do agravamento baseado puramente na sintomatologia e hemogramas.

O atributo alvo original, *Outcome*, foi substituído por uma estratégia mais granular. Para prever a possibilidade de agravamento extremo e de dores incapacitantes associadas a febre hemorrágica, adotou-se o campo *Joint_Pain* (Dor Articular) como principal discriminador. Criou-se a variável preditiva binária mediante a operação:

$$y = \begin{cases} 1, & \text{se sintoma for 'Severe' ou 'Moderate'} \\ 0, & \text{caso contrário} \end{cases} \quad (2)$$

Desta forma, os modelos são forçados a identificar os padrões clínicos em pacientes que evoluíram para os estágios mais incapacitantes da infecção.

B. Pré-processamento e Normalização

As colunas contínuas (temperatura corporal, contagem de plaquetas, contagem de leucócitos e duração da febre) passaram por um processo de padronização baseada no *Z-score* utilizando o *StandardScaler*. As características booleanas ou categóricas ordinais (*Headache*, *Retro_Orbital_Pain*, exames de anticorpos IgG/IgM e antígeno NS1, e mialgia) foram preservadas em sua escala natural para evitar a distorção da distância Euclidiana nas etapas de inicialização dos tensores. Os dados foram separados em 80% para treino e 20% para teste (*hold-out validation*), adotando uma semente estática (42) para garantir a reprodutibilidade dos resultados.

C. Arquitetura PyTorch

A rede foi programada sob o paradigma Orientado a Objetos utilizando a biblioteca PyTorch. A topologia final empírica encontrada foi uma rede densamente conectada 64-32-1:

- **Camada de Entrada:** 64 neurônios, seguida pela ativação ReLU.
- **Camada Oculta:** 32 neurônios, seguida pela ativação ReLU.
- **Camada de Saída:** 1 neurônio, com a função de ativação Sigmóide limitando as saídas preditivas no intervalo contínuo $[0, 1]$. Um limiar de 0.5 foi utilizado na conversão das probabilidades para classes diretas.

O gargalo arquitetural de redes neurais para diagnósticos médicos reside no balanceamento. Para lidar com isso, foi implementado um escalonador de custos diretamente na função de perda (BCELoss). Aplicou-se um peso de classe punitivo de razão 15:1. Matematicamente, a perda do erro num paciente de agravamento não identificado custava ao algoritmo 15 vezes o valor de errar um paciente leve. O modelo foi treinado por 2.000 épocas através do otimizador adaptativo Adam com taxa de aprendizado de 0.001.

IV. RESULTADOS E DISCUSSÃO

A. Avaliação das Métricas de Classificação

Após as inferências no conjunto de testes de dados ocultos à rede, foram compiladas as principais métricas de avaliação. As métricas foram sumarizadas da seguinte forma:

Tabela I
MÉTRICAS DE VALIDAÇÃO DO MLP

Métrica Preditiva	Valor Obtido
Acurácia Global	80.50%
Precisão	0.7903
Revocação (Recall)	0.8829
F1-Score	0.8340

Destaca-se expressivamente o valor da Revocação (88,29%). Na perspectiva de Engenharia Biomédica, o F1-Score elevado (0,8340) comprova que o sistema alcançou um balanço harmônico considerável. O fato de a precisão ser inferior à revocação (79% contra 88%) é um comportamento induzido artificialmente de forma proposital pelo vetor de pesos da

função de perda: admite-se que o sistema lance alguns "alarmes falsos" de agravamento (que resultam em observação extra do paciente), contanto que evite ao máximo que um paciente com perigo iminente vá para casa e sofra óbito.

B. Matriz de Confusão

A performance bruta da rede frente às classificações binárias é ilustrada visualmente na Matriz de Confusão disposta na Fig. 1.




Figura 1. Matriz de Confusão gerada pelas previsões do MLP no conjunto de teste. É notória a taxa de acerto no quadrante de Verdadeiros Positivos (98), em face a um número ínfimo de Falsos Negativos (13).

Interpretando a Fig. 1, dos 111 pacientes no conjunto de testes cujo quadro evoluiu como grave, o modelo identificou 98 casos com maestria e subestimou apenas 13 (Falso Negativo). Adicionalmente, detectou corretamente o estado não severo de 63 pessoas (Verdadeiro Negativo), lançando avisos preventivos desnecessários para 26 indivíduos (Falsos Positivos).

V. LIMITAÇÕES E CONCLUSÕES

O modelo computacional implementado atendeu à premissa de contornar problemas de generalidade por meio do viés no cálculo dos tensores de custo. A topologia PyTorch utilizada confirmou sua estabilidade e convergência rápida frente aos parâmetros fisiológicos estudados.

No entanto, é imperativo evidenciar, de forma pragmática, as profundas restrições técnicas da modelagem matemática aqui discutida, não devendo este sistema ser implementado no mundo real sem o intermédio de especialistas.

A primeira limitação estrutural está atrelada à dimensionalidade volumétrica do dataset. Utilizar apenas 1.000 instâncias retira a característica de universalidade necessária para algoritmos de IA [2]. Redes neurais densas necessitam de dezenas de milhares de instâncias para criar hiperplanos complexos sem correr o risco de sobreajuste local (*overfitting*).

A segunda e mais crítica limitação, evidenciada pela exclusão do dataset do governo brasileiro [3], está na matriz de correlações negligenciadas. O aprendizado da rede atual foi embasado puramente na biologia da virose (febre, antígenos,

plaquetas). Contudo, no contexto real, a chance de fatalidade por dengue não é unicamente biológica, mas estrutural. Fatores externos ocultos aos dados matemáticos — como o grau de pobreza da região do paciente, as péssimas condições de saneamento, a escassez de suprimento logístico de soro fisiológico nas Unidades Básicas de Saúde, o tempo de deslocamento do paciente doente por estradas deficitárias, entre outros — causam o colapso irreversível dos infectados. Uma rede neural fechada unicamente em sintomas sintéticos nunca será capaz de englobar o efeito mortal das deficiências sistêmicas da saúde coletiva.

Conclui-se que o Perceptron demonstrou altíssimo rigor analítico nas métricas matemáticas de base e superou sistemas comuns através de estratégias de priorização heurística. Contudo, para um verdadeiro avanço em sistemas inteligentes na saúde tropical, modelos híbridos de larga escala envolvendo IA socioeconômica aliada a parâmetros laboratoriais massivos tornam-se indispensáveis.

AGRADECIMENTOS

O autor gostaria de expressar seus profundos agradecimentos ao Prof. Dr. Pedro Thiago Valério de Souza (DETEC/UFERSA), docente do componente curricular PAM0466 - Sistemas Inteligentes, pelas diretrizes científicas consolidadas que instigaram a formulação e arquitetura metodológica do presente artigo.

REFERÊNCIAS

- [1] Ministério da Saúde do Governo Federal do Brasil. "Casos de dengue em 2024 passam de 6,4 milhões; mortes somam 5,9 mil". Agência Brasil. Disponível em: <https://agenciabrasil.ebc.com.br/saude/noticia/2025-01/casos-de-dengue-em-2024-passam-de-64-milhoes-mortes-somam-59-mil>. Acesso em: jun. 2026.
- [2] Ahmad, M. K., and Akter, F., "A Comprehensive Dengue Dataset of Bangladesh," Mendeley Data / Kaggle Repository, 2024. Disponível em: <https://www.kaggle.com/datasets/kawsarahmad/dengue-dataset-bangladesh>. Acesso em: jun. 2026.
- [3] Departamento de Informática do SUS (DATASUS). "Banco de Dados SINAN - Sistema de Informação de Agravos de Notificação (Dengue e Arboviroses)". Ministério da Saúde. Disponível em: <https://datasus.saude.gov.br/>. Acesso em: jun. 2026.